

FINAL EXAM:

CLASSIFICATION D'ESPÈCES D'ARBRES VIA NUAGES DE POINTS 3D ET APPROCHES MULTI-VUES 2D

Encadrer par:

**PROF.SAID
OHAMOUDOU**

Présente par:

**Arehal Bfissam,
El Faiz Rekaia,
Er-rreghay Hajar**

2024/2025



Plan

01 Introduction & Objectif

03 Visualisation et Prétraitement

05 Résultats et Analyse

02 Dataset

04 Méthodes

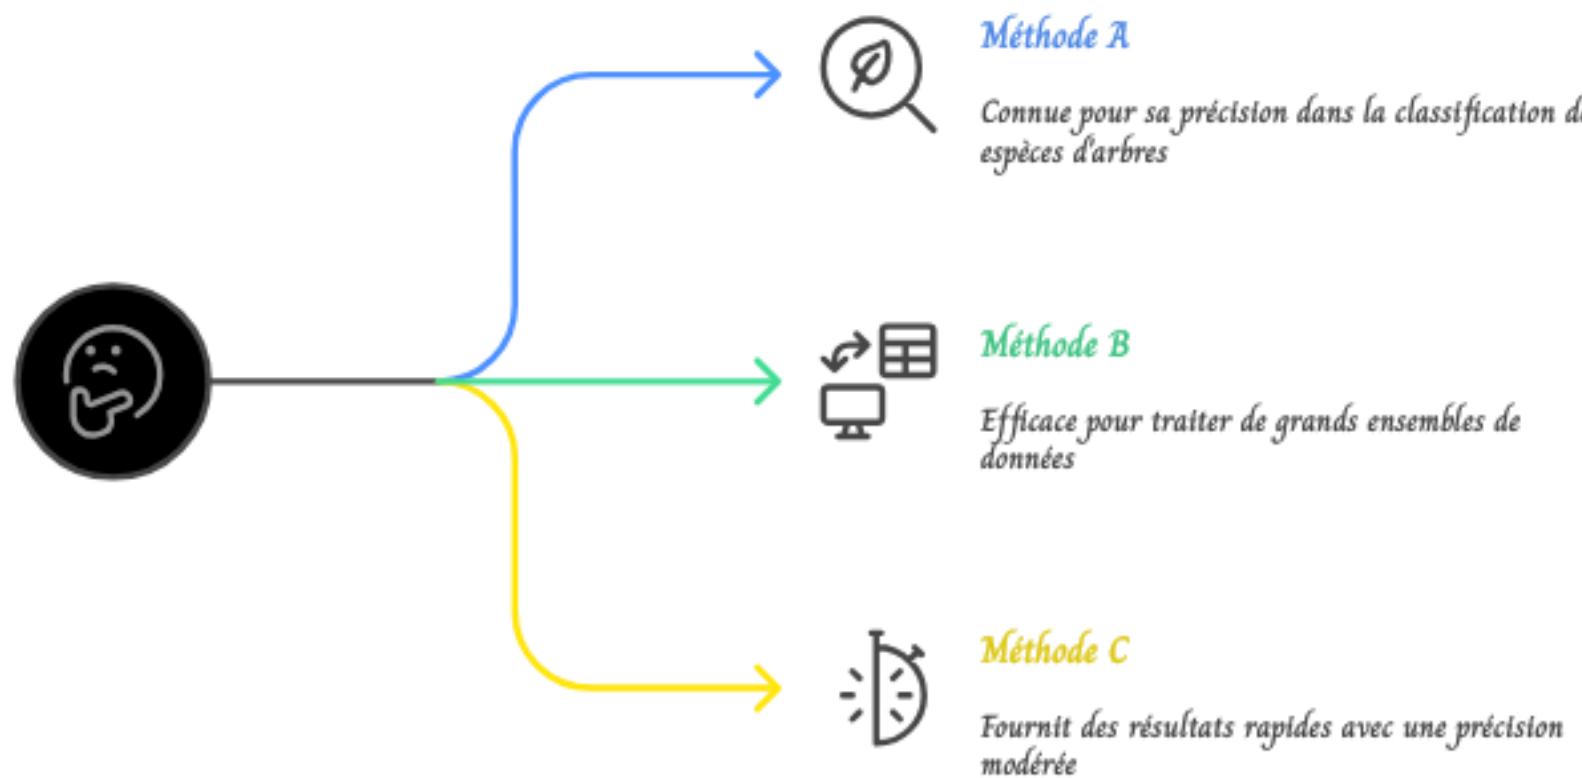
06 Conclusion et Perspectives

01

Introduction & Objectif

La reconnaissance des espèces d'arbres est une tâche importante pour l'écologie et la gestion des forêts. Dans ce projet, nous utilisons des données en 3D, appelées nuages de points, afin de classer différentes espèces d'arbres. L'objectif est de comparer plusieurs méthodes et de déterminer laquelle donne les meilleurs résultats.

L'objectif de ce projet est de comparer différentes méthodes de classification afin de reconnaître les espèces d'arbres à partir de données 3D et d'identifier la méthode la plus efficace.



02

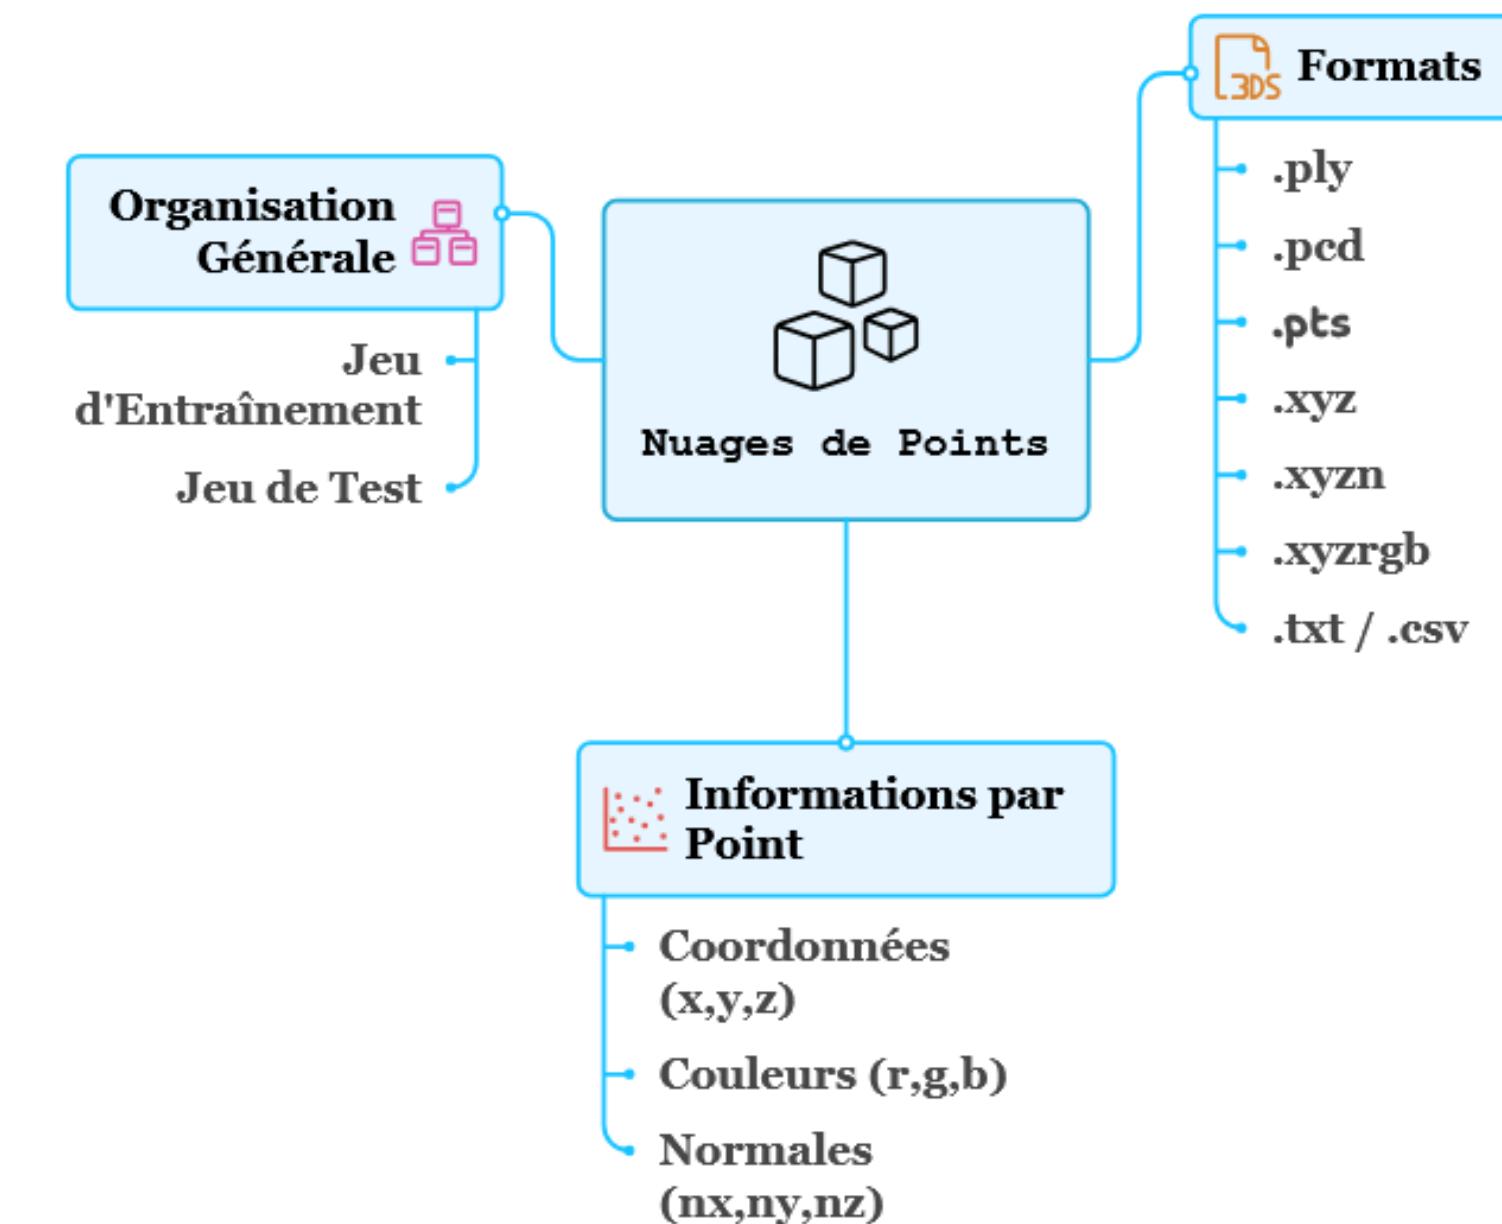
Dataset

Le jeu de données utilisé est constitué de nuages de points 3D représentant des arbres scannés numériquement. Un nuage de points est un ensemble de coordonnées spatiales (x,y,z).

Chaque point décrivant une position précise dans l'espace.

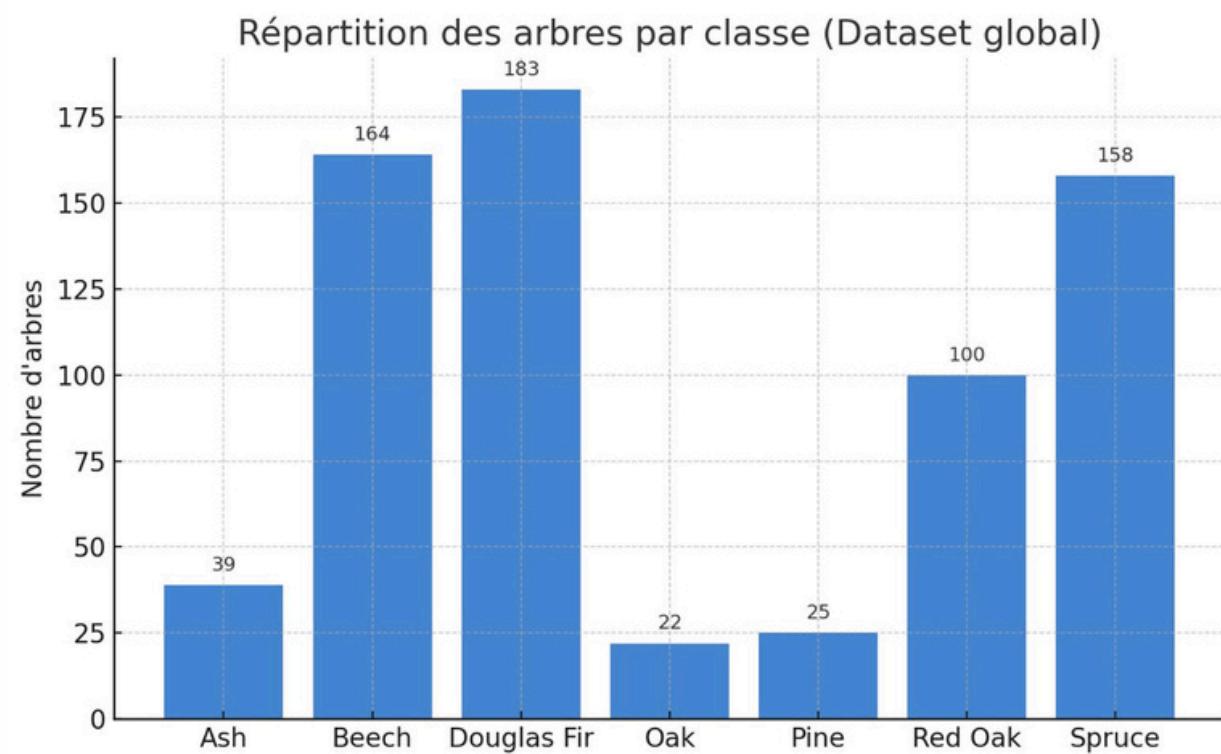
En agrégant ces points, on obtient une représentation fidèle de la géométrie globale de l'arbre (tronc, branches, volume général).

Formats et Structure des Nuages de Points



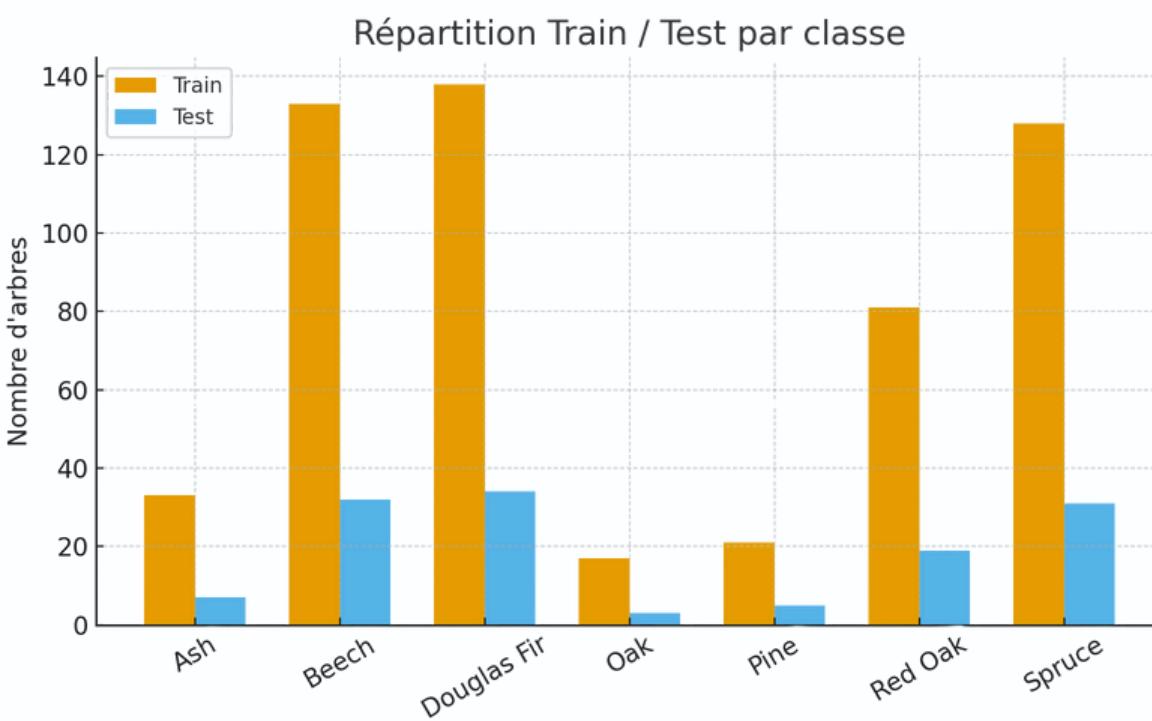
Répartition globale

La première étape consiste à analyser la distribution globale du dataset.



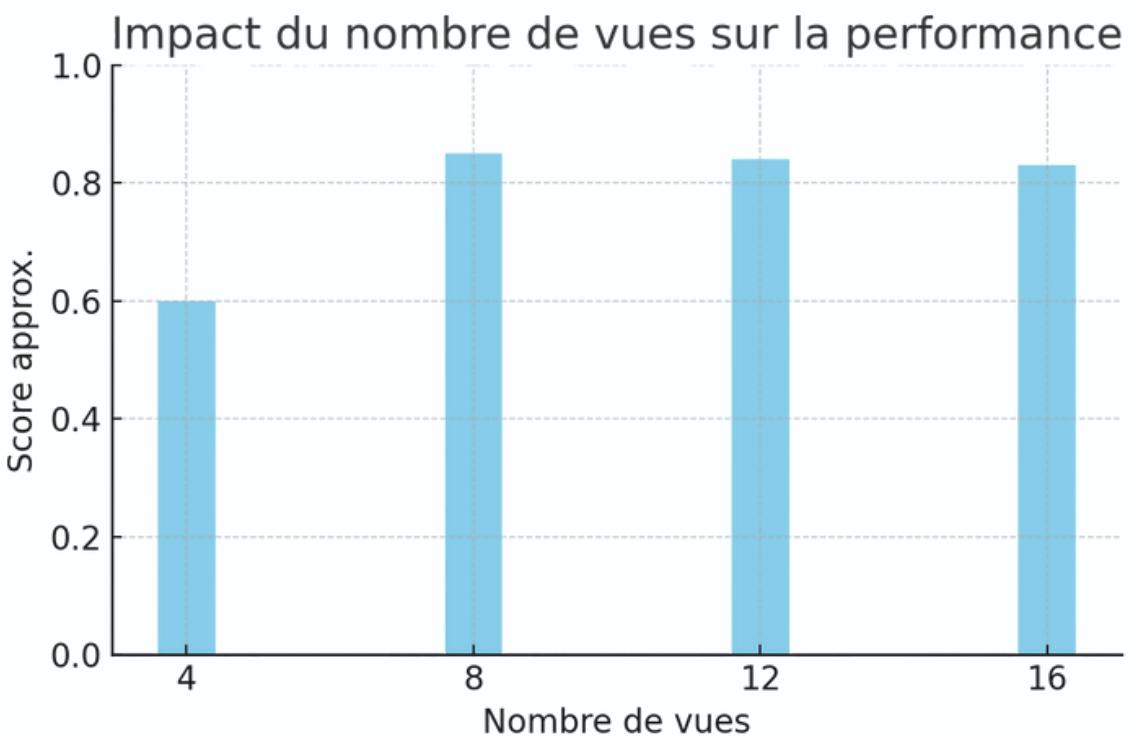
Répartition Train/Test

Le dataset a été séparé en un ensemble d'entraînement et un ensemble de test. La répartition par classe reste cohérente entre les deux splits, ce qui permet d'évaluer les modèles dans des conditions équilibrées et réalistes.



Impact du nombre de vues

Dans les méthodes indirectes, chaque arbre est projeté en plusieurs images 2D. Le choix du nombre de vues influence directement les performances

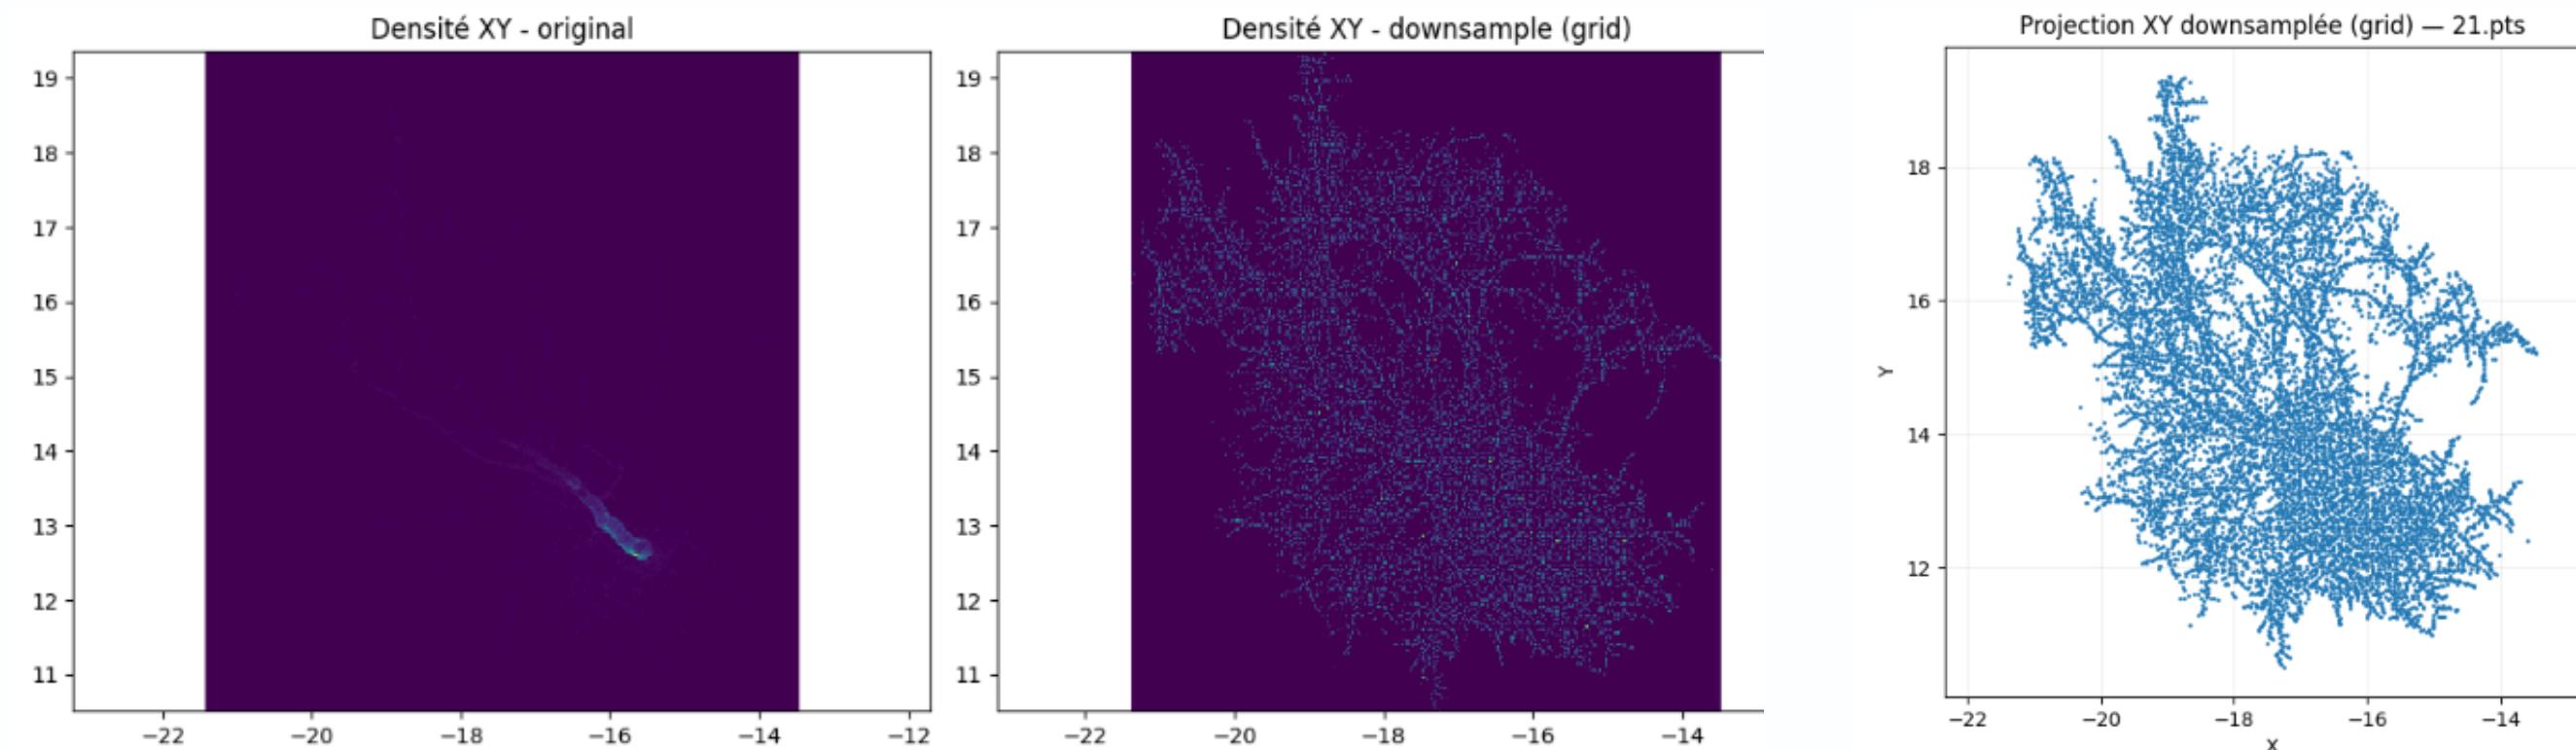


03

Visualisation et Prétraitement

Avant toute étape de prétraitement, la visualisation est essentielle. Elle permet non seulement de comprendre la distribution et la qualité des données, mais aussi d'anticiper les choix de normalisation, d'équilibrage ou de nettoyage nécessaires. En résumé, elle transforme un dataset brut en une base exploitable et fiable pour l'apprentissage automatique.

Downsampling (Exemple d'affichage 2D):



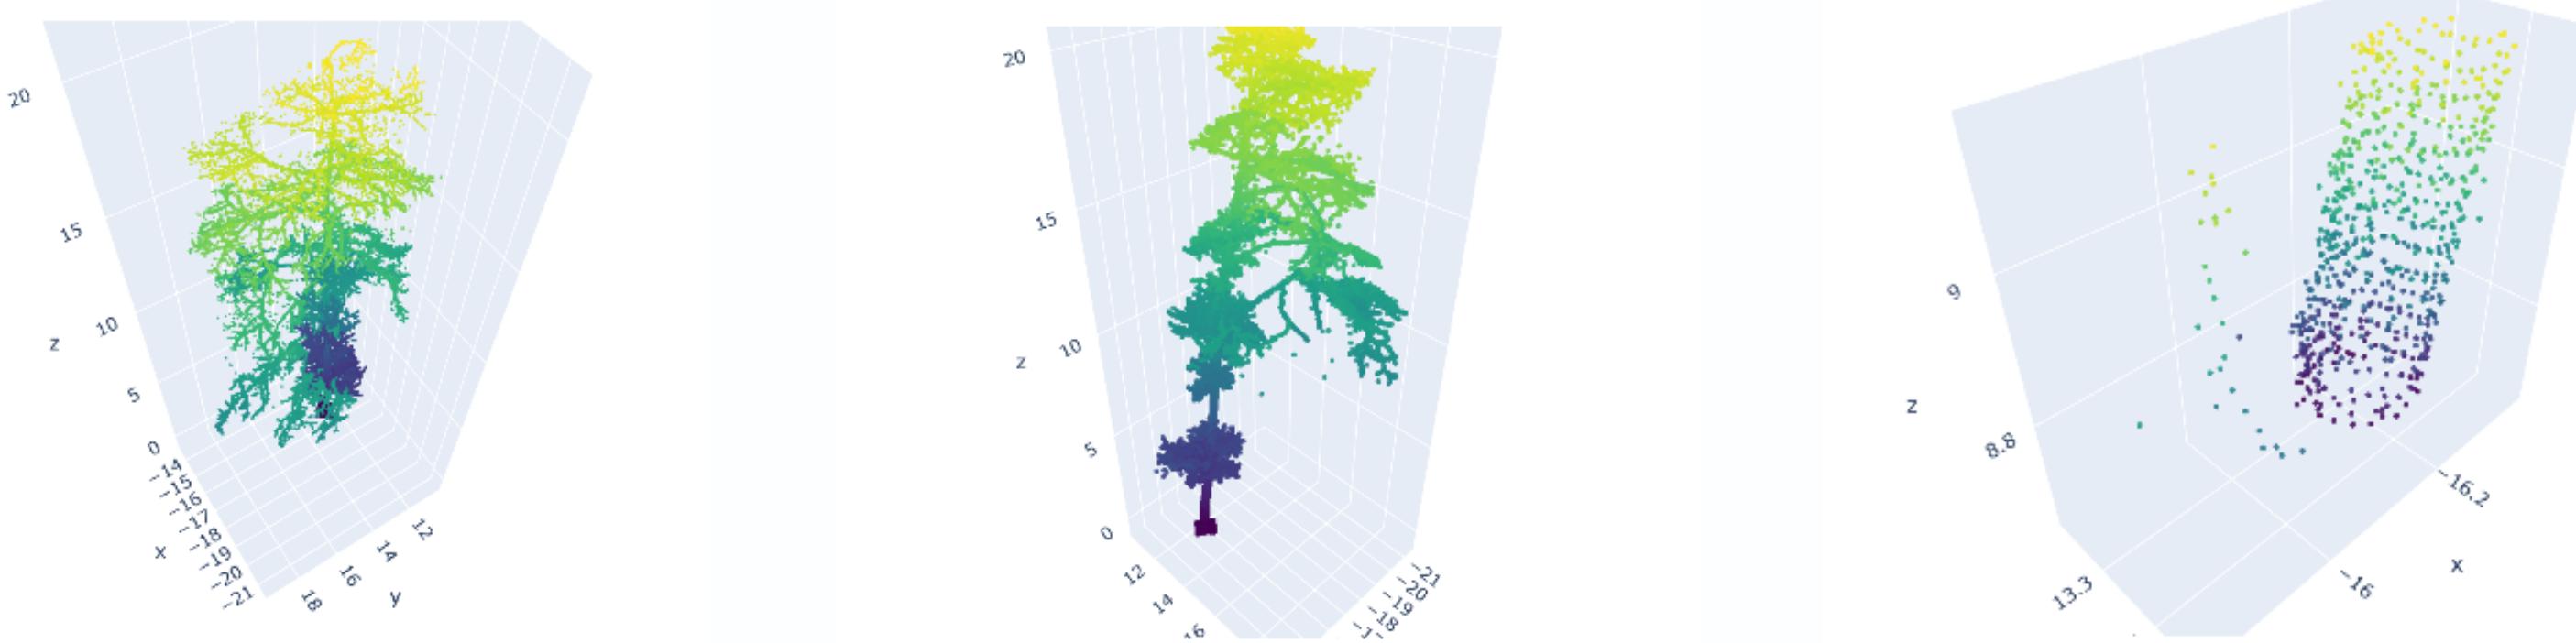
Les images trois présentent un nuage de points avant et après downsampling par grille:

- la projection XY des points échantillonnés,
- la densité originale montrant une forte concentration dans une zone précise,
- la densité après réduction, qui conserve la structure globale tout en simplifiant la répartition des points.

03

Visualisation et Prétraitement

Scatter 3D interactif(Exemple 3D):



L'image montre un nuage de points 3D interactif représentant une structure verticale colorée selon la hauteur (axe Z).

On y voit trois vues différentes :

- une vue inclinée.
- une vue de face qui met en évidence la forme générale.
- eversion réduite qui garde la structure tout en simplifiant les points.

03

Visualisation et Prétraitement

Le prétraitement a été adapté selon la nature des méthodes de classification (multi-vue 2D, méthodes directes 3D, ou quasi-directes par descripteurs).

L'objectif est d'assurer une qualité homogène des données tout en préparant des représentations exploitables par les modèles.

Méthodes multi-vue (2D):

- Nettoyage des nuages de points bruts pour supprimer les points aberrants.
- Réduction de densité à l'aide d'un downsampling voxel afin de diminuer le nombre de points tout en conservant la structure.
- Alignement des arbres par analyse en composantes principales (PCA), garantissant une orientation cohérente avec l'axe vertical (+Z).
- Normalisation par boîte englobante (AABB) pour recentrer et homogénéiser la taille, tout en préservant les dimensions réelles.
- Génération de huit vues 2D par arbre à partir des nuages normalisés.
- Redimensionnement des images en 224×224 pixels.
- Normalisation des canaux selon les statistiques ImageNet.
- Enrichissement par augmentation de données : recadrage aléatoire, retournements horizontaux, légères perturbations de couleur.

03

Visualisation et Prétraitement

Méthodes quasi-directes (descripteurs 3D + apprentissage classique)

Dans ce cadre, les nuages ont été traités par nettoyage, réduction voxel, alignement PCA et normalisation AABB. Sur ces nuages homogénéisés, différents descripteurs géométriques ont pu être extraits (tels que FPFH, Spin Images ou Shape Histograms), constituant les vecteurs de caractéristiques utilisés par les modèles d'apprentissage automatique classiques.

Méthodes directes (3D deep learning):

Pour les réseaux de neurones traitant directement les nuages de points (PointNet, DGCNN), les nuages ont été soumis aux mêmes opérations de nettoyage, réduction de densité, alignement PCA et normalisation AABB.

Un échantillonnage par la technique du Farthest Point Sampling (FPS) a été appliqué afin de conserver un nombre fixe de 1024 points par arbre, garantissant ainsi une taille d'entrée standard pour les architectures 3D.



Méthodes indirectes

Descripteurs Classiques + SVM

Extraction de descripteurs SIFT des vues 2D, quantifiés par Bag-of-Words, puis classification par un SVM polynomial pour les relations non linéaires.

CNN from Scratch

Entraînement d'un CNN avec des poids aléatoires sur les vues projetées pour apprendre des filtres spécifiques au dataset.

CNN Pré-entraîné (Fine-tuning)

Réutilisation d'un CNN pré-entraîné (ex: ResNet50 sur ImageNet), avec réentraînement des dernières couches pour adapter le modèle aux arbres.

CNN Pré-entraîné + SVM

Le CNN sert d'extracteur de caractéristiques (features 2D) classifiées par un SVM polynomial, combinant puissance du CNN et robustesse du SVM.

Transfer Learning

Geler la majorité des couches du CNN pré-entraîné et n'entraîner que la dernière couche pour une convergence plus rapide et une limitation de l'overfitting.

Fusion SIFT + CNN

Combinaison de descripteurs SIFT Bag-of-Words avec les représentations profondes d'un CNN pour une représentation plus riche, classifiée par SVM.

04 Méthodes de Classification



Méthodes quasi-directes (3D descriptors + ML);

cette méthode quasi-directes extraient des descripteurs 3D (géométriques et statistiques) à partir des nuages de points prétraités, puis les classifient avec un SVM polynomial (ou RBF/ensemble), offrant robustesse et capacité à modéliser des relations non linéaires même avec peu de données.



Méthodes directes (deep learning sur nuages 3D);

- PointNet : traite directement les nuages de points à l'aide de MLP partagés et d'un max pooling global. Il est simple et invariant à l'ordre des points, mais reste limité pour la capture de la géométrie locale.
- DGCNN : améliore PointNet en construisant des graphes k-NN dynamiques et en appliquant des convolutions sur les arêtes (EdgeConv). Cela permet de mieux représenter les structures locales fines, mais au prix d'un coût de calcul plus élevé.

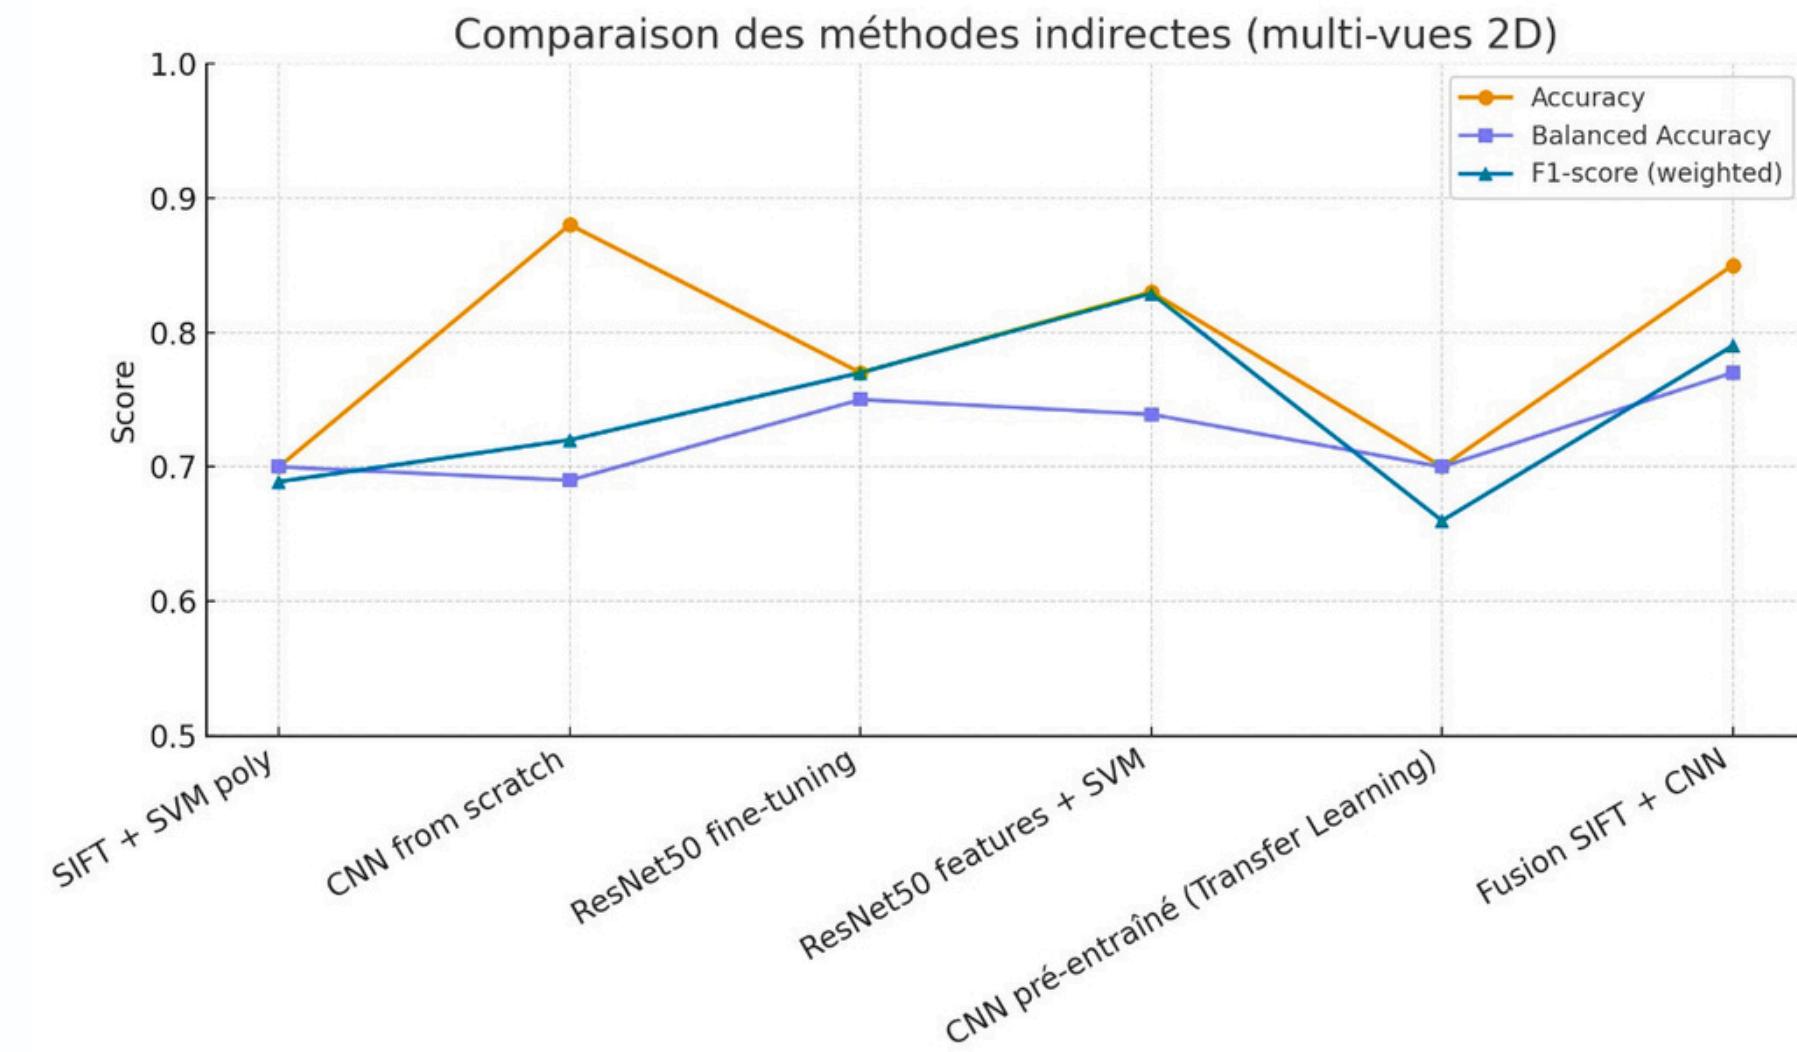
➡️ Méthodes indirectes

1. Tableau comparatif des méthodes (résultats expérimentaux): Résultats expérimentaux comparant plusieurs approches de classification multi-vue et hybrides.

Méthode	Accuracy	Balanced Acc	Macro F1
M1 – SIFT Bag-of-Words + SVM polynomial	0.70	0.70	0.689
M2 – CNN from scratch	0.75	0.65	0.654
M3 – ResNet50 fine-tuning	0.77	0.7516	0.7771
M4 – ResNet50 features + SVM	0.8321	0.7391	0.8299
M5 – CNN pré-entraîné (Transfer Learning)	0.7985	0.7775	0.7687
M6 – Fusion SIFT-BoW + CNN	0.855	0.771	0.795

L'évolution des résultats montre que les approches profondes et hybrides offrent une nette supériorité par rapport aux méthodes classiques. La fusion ResNet50 + SIFT-BoW (M6) constitue la solution la plus robuste et performante pour la classification multi-classes étudiée.

Comparaison des méthodes indirectes



Interprétation :

Les approches multi-vues exploitent efficacement les projections 2D, mais restent limitées par la perte d'information spatiale.

Les modèles pré-entraînés et la fusion SIFT+CNN apportent plus de stabilité et une meilleure capacité de généralisation.



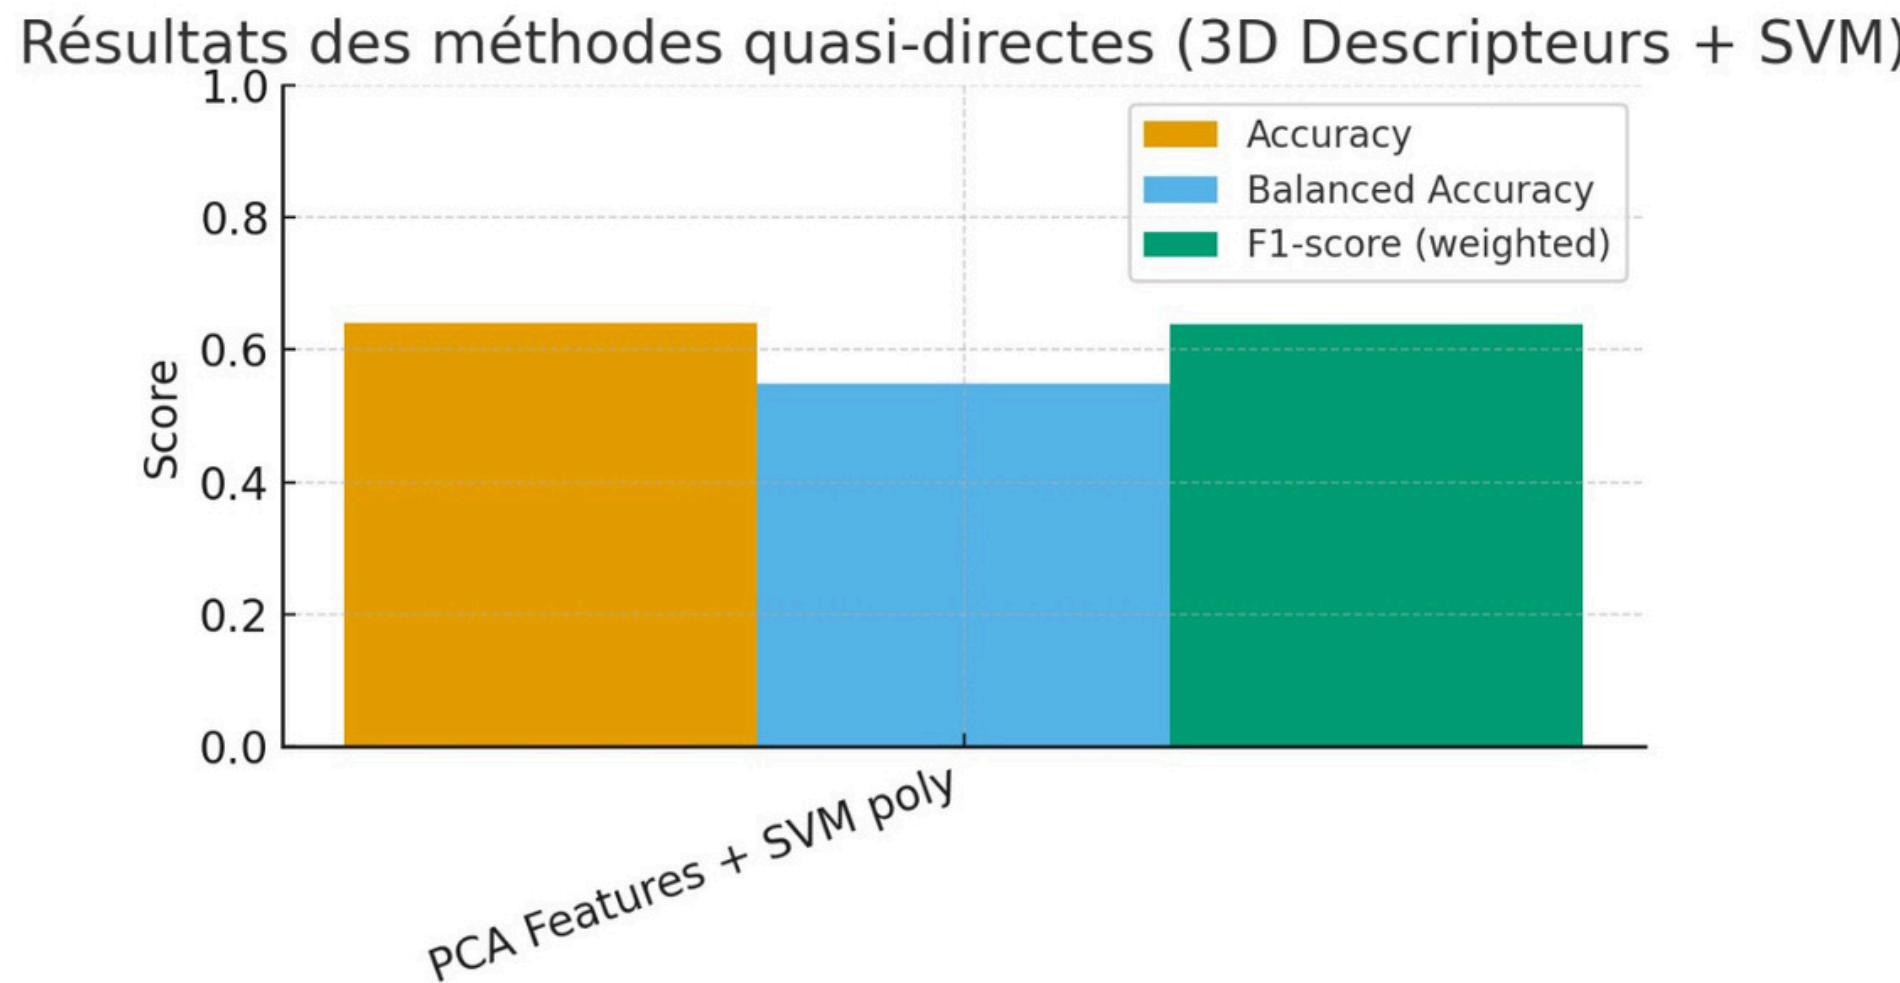
Méthodes quasi-directes (3D descriptors + ML);

Méthode	Accuracy	Balanced Accuracy	F1-score (weighted)
PCA Features + SVM (poly)	0.641	0.548	0.638

Interprétation :

- Les descripteurs PCA associés à un SVM capturent partiellement l'information 3D.
- Les performances restent limitées (< 65%), preuve que les représentations manuelles ne suffisent pas pour modéliser la complexité des nuages de points.
- Ce modèle sert surtout de baseline de comparaison.

Résultats des méthodes quasi-directes (3D Descripteurs + SVM)



Interprétation :

Avec environ 64% de précision, ces méthodes sont rapides et interprétables mais peu performantes.

Elles peinent à distinguer les essences proches car les descripteurs manuels capturent mal les détails fins.

Clouds Méthodes directes (deep learning sur nuages 3D);

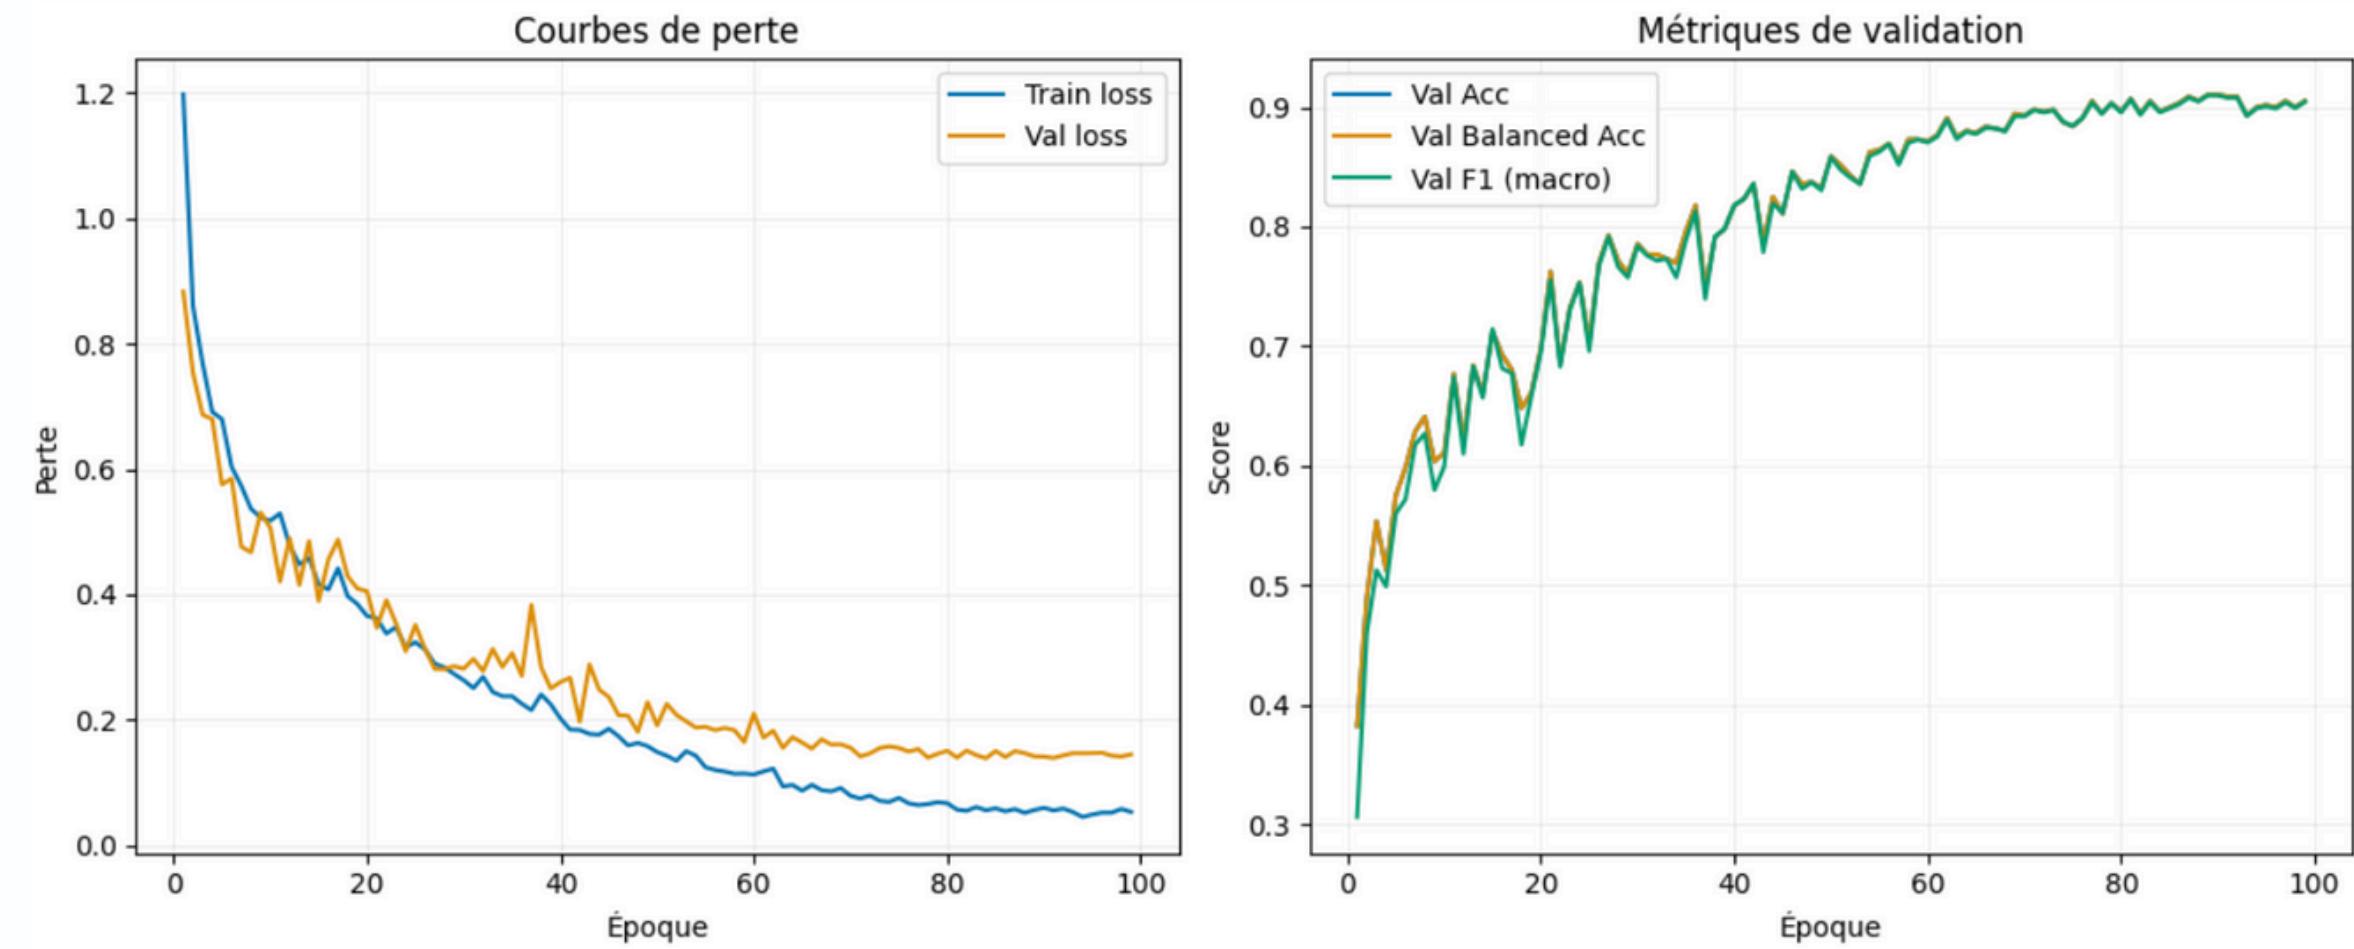
Méthode	Accuracy	Balanced Accuracy	F1-score (weighted)
PointNet	0.930	0.930	0.929
DGCNN	0.994	0.994	0.994

Interprétation :

Les méthodes directes exploitent directement les nuages de points bruts.

- PointNet atteint environ 93 % de précision, grâce à son architecture simple qui apprend des invariants globaux sur les points. Son avantage est la rapidité et l'invariance à l'ordre des points, mais il capture moins bien les structures locales.
- DGCNN, en revanche, introduit les graphes dynamiques de voisinage (EdgeConv + kNN réactualisé), ce qui lui permet de mieux distinguer des essences morphologiquement proches, comme Douglas Fir et Spruce. Résultat : une performance quasi parfaite (~99 % accuracy/F1).
- Ces résultats confirment que l'intégration des relations locales entre points apporte un net gain par rapport à un traitement global uniquement.

Résultats des méthodes directes (PointNet)

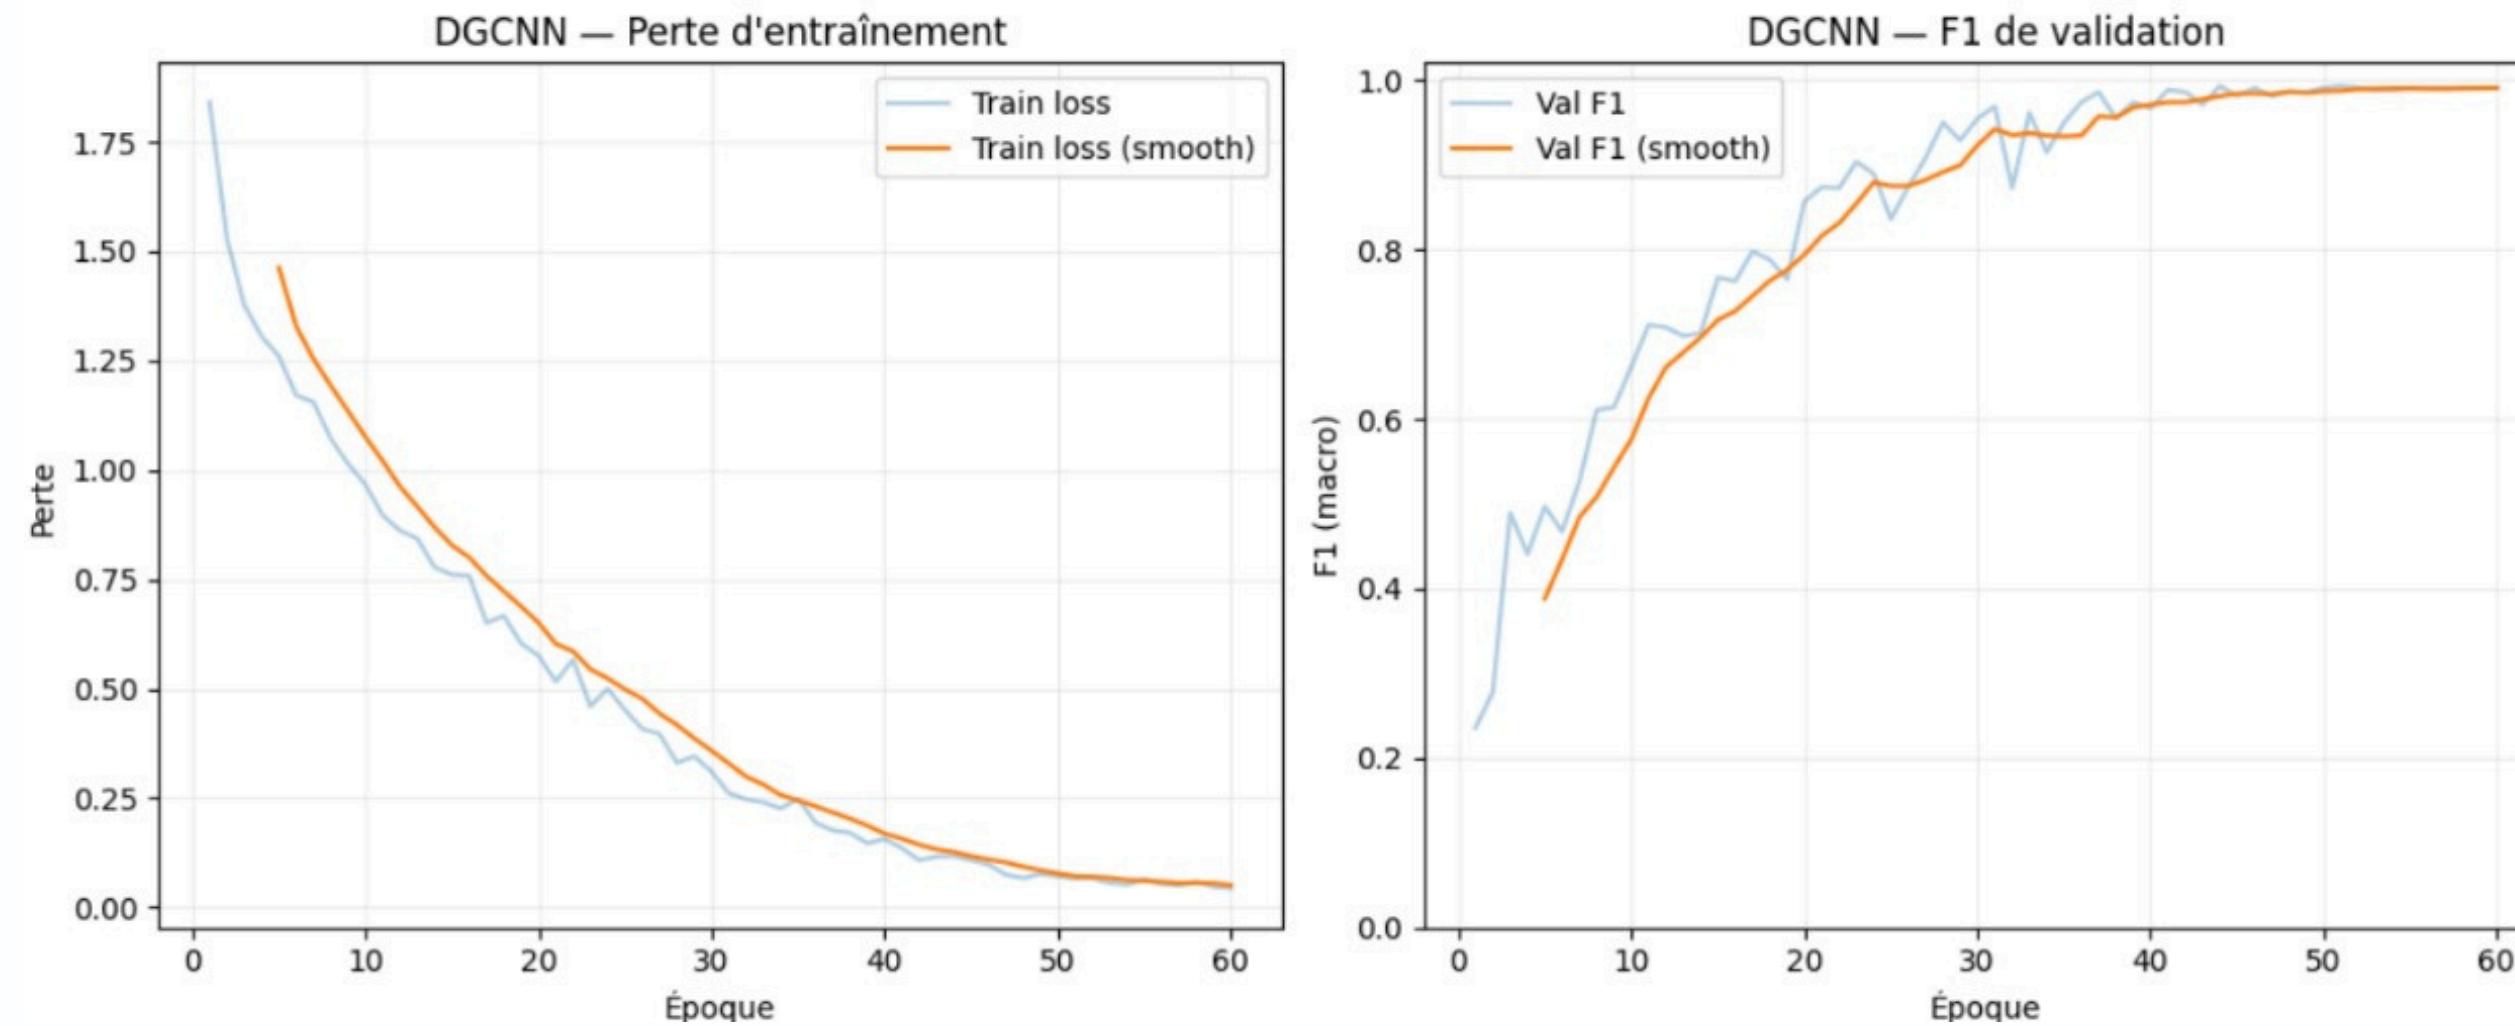


Interprétation :

PointNet apprend de manière stable et atteint 93% de précision.

Il exploite bien la structure globale des nuages de points, mais reste limité pour la géométrie locale.

Résultats des méthodes directes (DGCNN)



Interprétation :

DGCNN montre une convergence rapide et des scores quasi parfaits ($\approx 99\%$).

Grâce à ses graphes dynamiques, il capture efficacement les détails locaux et surpassé toutes les autres méthodes.

Résultats et Discussion

Une hiérarchie claire se dégage des performances des différentes approches.

Méthodes Directes

1

PointNet (93%) et DGCNN (99%) offrent les meilleures performances en exploitant la structure des nuages de points 3D, malgré un coût de calcul plus élevé.

Méthodes Indirectes

2

Les CNN pré-entraînés (80-88%) représentent un bon compromis coût/précision, tirant parti du transfert d'apprentissage même si l'information 3D est partiellement perdue lors de la projection 2D.

3

Méthodes Quasi-Directes

Avec 64% d'accuracy, elles sont légères et interprétables, offrant une alternative rapide et peu coûteuse, mais peinent sur la micro-géométrie fine des arbres.

En résumé, les méthodes directes sont les plus performantes, les indirectes offrent un bon équilibre, et les quasi-directes conviennent aux environnements contraints par la simplicité.

conclusion

En conclusion, pour la classification 3D des essences d'arbres, les méthodes directes offrent les meilleures performances, notamment DGCNN grâce à sa prise en compte fine de la géométrie locale. Les approches multi-vues constituent une alternative compétitive avec un coût réduit, tandis que les méthodes quasi-directes restent rapides, robustes et interprétables, mais limitées face à des essences morphologiquement proches. Le choix de la méthode dépend donc du compromis souhaité entre précision, complexité et ressources disponibles.

perspective

- Élargir et équilibrer le jeu de données (collecte ciblée, augmentation 3D dédiée)
- Tester des variantes plus récentes (PointNet++, 3D Graph/Transformer)
- Intégrer des signaux supplémentaires (normales, intensité, features radiométriques)
- Explorer des schémas de fusion multi-vues + 3D direct



**MERCI POUR
VOTRE ATTENTION**